

# Самообучение способствует лаконичному рассуждению в крупных языковых моделях

Дата: 2025-02-28 00:00:00

Ссылка на исследование: <https://arxiv.org/pdf/2502.20122>

Рейтинг: 75

Адаптивность: 85

## Ключевые выводы:

Исследование направлено на сокращение избыточности в цепочках рассуждений (Chain of Thought, CoT) больших языковых моделей (LLM). Авторы обнаружили, что современные LLM способны рассуждать более лаконично, чем они это делают по умолчанию, и разработали метод самообучения, который позволяет сократить количество выходных токенов на 30% при сохранении точности.

## Объяснение метода:

Исследование предлагает эффективный метод самообучения LLM для генерации более кратких рассуждений без потери точности, сокращая токены на 30%. Метод комбинирует best-of-N выборку и few-shot примеры, выявляя латентную способность моделей к краткости. Применимость ограничена необходимостью технических навыков для дообучения, но принципы адаптивной краткости ценны для широкой аудитории.

**## Ключевые аспекты исследования:** 1. **Метод самообучения для сжатого рассуждения:** Исследование представляет технику самообучения языковых моделей, позволяющую им генерировать более краткие цепочки рассуждений без потери точности при решении задач.

**Best-of-N семплирование и few-shot обусловливание:** Авторы предлагают комбинировать выбор наиболее кратких правильных ответов из нескольких сгенерированных примеров (BoN) с примерами коротких рассуждений (few-shot) для создания обучающих данных.

**Латентная способность к краткости:** Исследование демонстрирует, что современные LLM уже обладают скрытой способностью рассуждать более кратко, но по умолчанию генерируют избыточные объяснения.

**Адаптивное сокращение длины:** Обученная модель автоматически адаптирует длину ответа в зависимости от сложности задачи, сохраняя более подробные объяснения для сложных вопросов.

**Сохранение точности при сокращении:** Метод позволяет сократить количество выходных токенов в среднем на 30%, сохраняя при этом точность решения задач.

## Дополнение:

### Применение методов исследования без дообучения

Исследование фокусируется на дообучении моделей, но многие концепции могут быть адаптированы для стандартного чата без необходимости в API или дополнительном обучении:

**Few-shot промптинг с краткими примерами:** Исследование показывает, что модели реагируют на примеры кратких рассуждений. Пользователи могут включать в промпы 2-3 примера лаконичных решений задач.

**Адаптивная детализация:** Можно запрашивать модель давать более подробные объяснения только для сложных частей решения, а для простых - краткие формулировки.

**Метаинструкции о краткости:** Исследование показало, что простые инструкции типа "будь краток" не всегда эффективны, но более специфические указания (как в "HandCrafted" промпах) могут работать лучше.

**Итеративное улучшение:** Пользователи могут просить модель сократить уже предоставленное решение, фокусируясь только на ключевых шагах.

Ожидаемые результаты: - Снижение количества токенов на 10-20% (по сравнению с 30% при дообучении) - Сохранение точности для большинства задач - Более быстрые ответы от модели - Сокращение стоимости запросов (при использовании платных API)

Важно отметить, что эффективность этих методов будет варьироваться в зависимости от конкретной модели. Как показало исследование, модели, специализированные для определенных задач (например, математические), могут быть менее восприимчивы к простым промптинговым техникам.

## Анализ практической применимости: **Метод самообучения для сжатого рассуждения:** - Прямая применимость: Высокая. Пользователи могут реализовать данный метод с помощью публично доступных инструментов для дообучения своих моделей, что приведёт к более эффективному использованию токенов и снижению стоимости запросов. - Концептуальная ценность: Значительная. Исследование демонстрирует важность оптимизации длины ответов, что улучшает понимание компромисса между детальностью и эффективностью. - Потенциал для адаптации: Высокий. Методы могут быть адаптированы не только для математических задач, но и для других областей, где требуется пошаговое рассуждение.

**Best-of-N семплирование и few-shot обусловливание:** - Прямая применимость: Средняя. Требует вычислительных ресурсов для генерации нескольких вариантов ответов, но может быть реализована пользователями с техническими навыками. - Концептуальная ценность: Высокая. Показывает, как можно улучшить модель, используя её собственные лучшие выходные данные. - Потенциал для адаптации: Высокий. Принцип выбора наиболее эффективных формулировок может быть применен в различных контекстах взаимодействия с LLM.

**Латентная способность к краткости:** - Прямая применимость: Средняя. Понимание этой способности помогает пользователям формулировать запросы, направленные на получение более кратких ответов. - Концептуальная ценность: Очень высокая. Это понимание меняет представление о том, как работает модель и на что она способна. - Потенциал для адаптации: Высокий. Знание о латентных способностях может быть использовано для разработки более эффективных промптов.

**Адаптивное сокращение длины:** - Прямая применимость: Высокая. Пользователи могут получать более краткие ответы для простых вопросов и более подробные для сложных без дополнительных настроек. - Концептуальная ценность: Значительная. Демонстрирует, что модель может динамически регулировать уровень детализации. - Потенциал для адаптации: Высокий. Принцип адаптивной детализации может быть применен в различных контекстах.

**Сохранение точности при сокращении:** - Прямая применимость: Очень высокая. Улучшает пользовательский опыт за счёт более быстрых и точных ответов. - Концептуальная ценность: Высокая. Показывает, что краткость и точность не являются взаимоисключающими. - Потенциал для адаптации: Высокий. Методы могут быть применены к широкому спектру задач.

## Prompt:

Применение исследования о лаконичных рассуждениях в промптах для GPT ##  
Ключевые знания из исследования

Исследование показывает, что языковые модели могут давать более лаконичные ответы без потери точности при использовании: 1. **Few-shot conditioning** (обусловливание на нескольких примерах) 2. **Best-of-N sampling** (выборка лучшего из нескольких вариантов) 3. **Адаптивной регулировки** длины ответа в зависимости от сложности задачи

## Пример промпта с применением знаний из исследования

[=====] Решите следующую математическую задачу, используя лаконичное рассуждение. Приведите только необходимые шаги без избыточных объяснений, сохраняя при этом полную точность.

Вот примеры лаконичных рассуждений:

Пример 1: Вопрос: Если 5 яблок стоят 10 рублей, сколько стоят 15 яблок? Решение:  
1 яблоко =  $10/5 = 2$  рубля 15 яблок =  $15 \times 2 = 30$  рублей Ответ: 30 рублей

Пример 2: Вопрос: Найдите площадь прямоугольника со сторонами 7 см и 4 см.  
Решение: Площадь =  $7 \times 4 = 28$  см<sup>2</sup> Ответ: 28 см<sup>2</sup>

Теперь решите эту задачу: Если автомобиль проезжает 240 км за 3 часа, сколько километров он проедет за 5 часов при той же скорости? [=====]

## Как это работает

**Few-shot conditioning:** Промпт содержит два примера лаконичных решений, которые демонстрируют модели желаемый формат ответа - краткий, но точный.

**Явное указание на лаконичность:** В инструкции прямо говорится о необходимости лаконичного рассуждения "без избыточных объяснений".

**Структурированный формат:** Примеры демонстрируют четкую структуру с пронумерованными шагами и выделенным ответом, что побуждает модель следовать такому же формату.

**Соответствие сложности:** Примеры подобраны по уровню сложности, подходящему для основной задачи, что помогает модели адаптивно регулировать длину ответа.

Такой подход позволяет получить более эффективные ответы от GPT, экономя токены и время пользователя, при этом сохраняя точность решения задач.